ESC FINAL PROJECT

Bankruptcy Classification – EDA까지

ESC 5조

TABLE

조원 소개

01

조원 소개

ESC 5조

김윤전

5조 조장!

김내히

5조의 유일한 신입!

정재은

5조의 에이스, 파잘알!

홍익선

왠지 부조장의 느낌!

엄상준

늙은이

데이터 및 프로젝트
소개

02

데이터 및 프로젝트 소개

Bankruptcy Classification

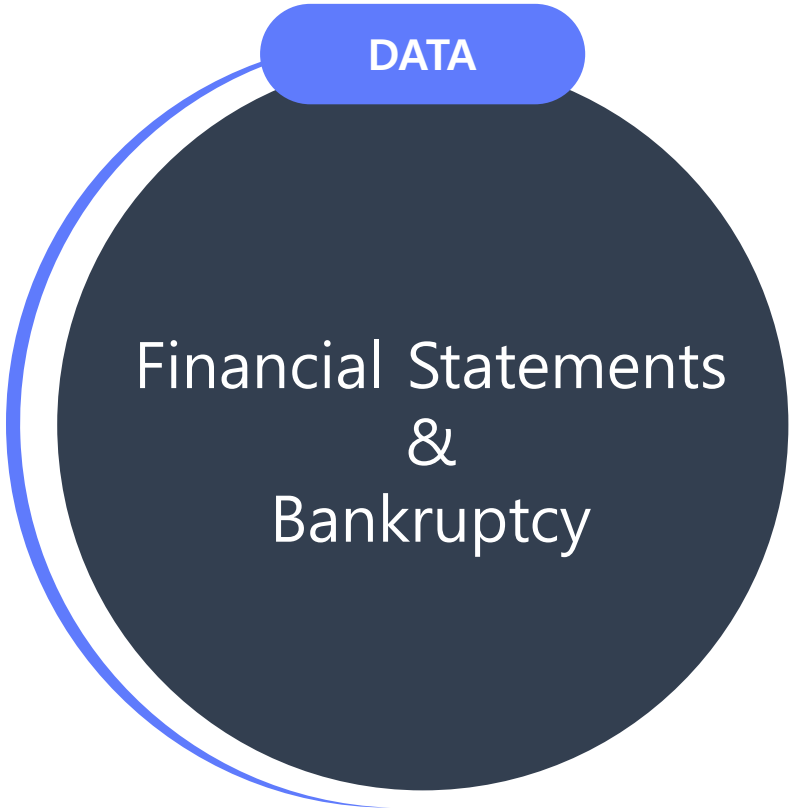

데이터 개수(Observations): 9792

변수 개수: 65

Target Class: 파산(1) / 정상(0)

파산기업 수: 515, **정상기업 수:** 9277

변수

X1 net profit / total assets

X2 total liabilities / total assets

등과 같이 재무상태표의 내용을 조합한 수치들.

프로젝트 목표

- 변수들을 통해 기업의 파산여부 예측
- 기업의 파산여부에 어떠한 변수들이 중요한지 확인

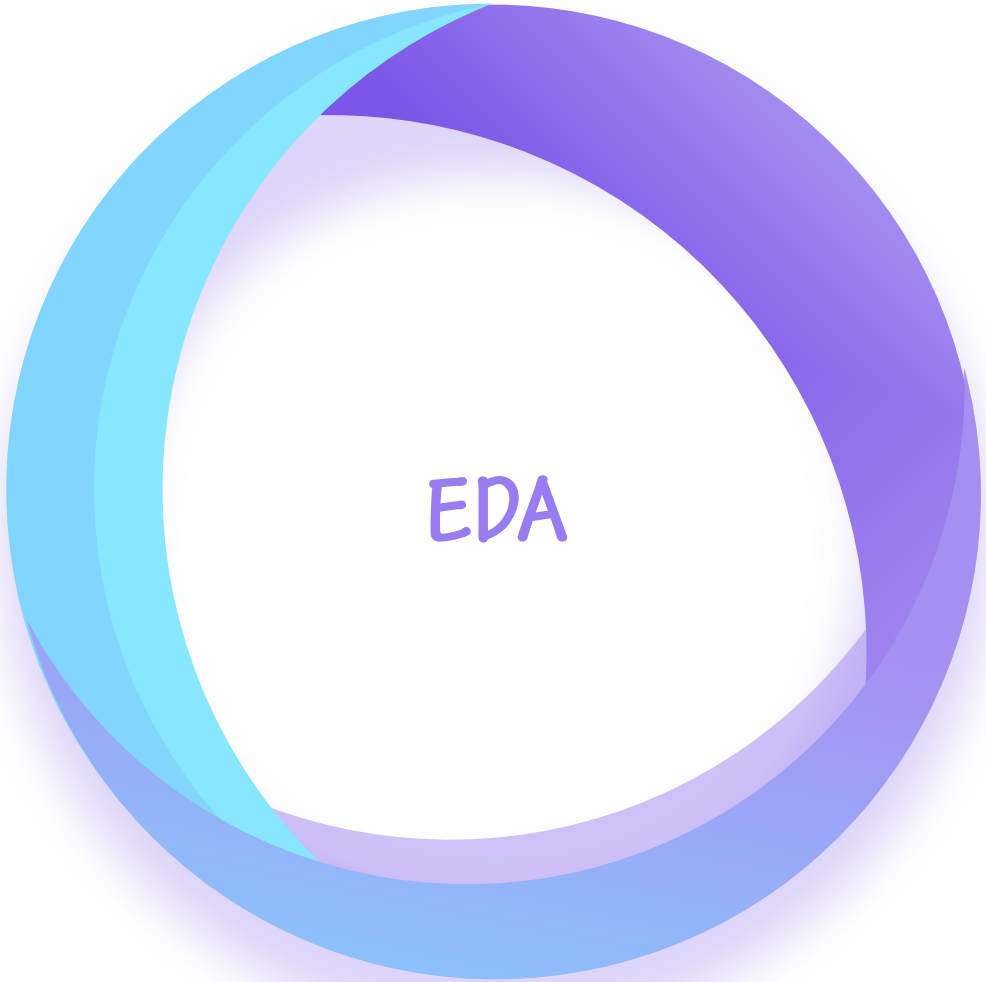
EDA

EDA

NA Imputation

Classification: 재무상태표와 2년 후 파산 여부

- 9792행, 65열, Taget 'class' (파산 기업 1, 정상 기업 0)
- Train-Test split 7 대 3 (stratified split, train만 제공)
- 결측치 없음
- 당신은 지중은행 여신담당부서에 데이터 분석 직군으로 입사한 신입사원입니다. 당신의 역할은 기업의 재무상태표를 보고 파산 확률을 예측해 여신 여부를 결정하는 것입니다. 당신의 상사가 당신에게 기대하는 바는 다음과 같습니다.

  i. 기업의 재무상태표, 손익계산서, 현금흐름표 등 각종 항목이 서로 어떤 관련이 있는가?
  ii. 기업의 2년 후 파산 여부를 재무상태표 항목으로 보고 예측할 수 있는가?
  iii. 기업의 재무상태표에서 여신 여부를 결정하기 위해 무엇을 중점으로 봐야 하는가?

20-1 ESC FINAL PROJECT 설명에서 발췌

03

EDA

NA Imputation

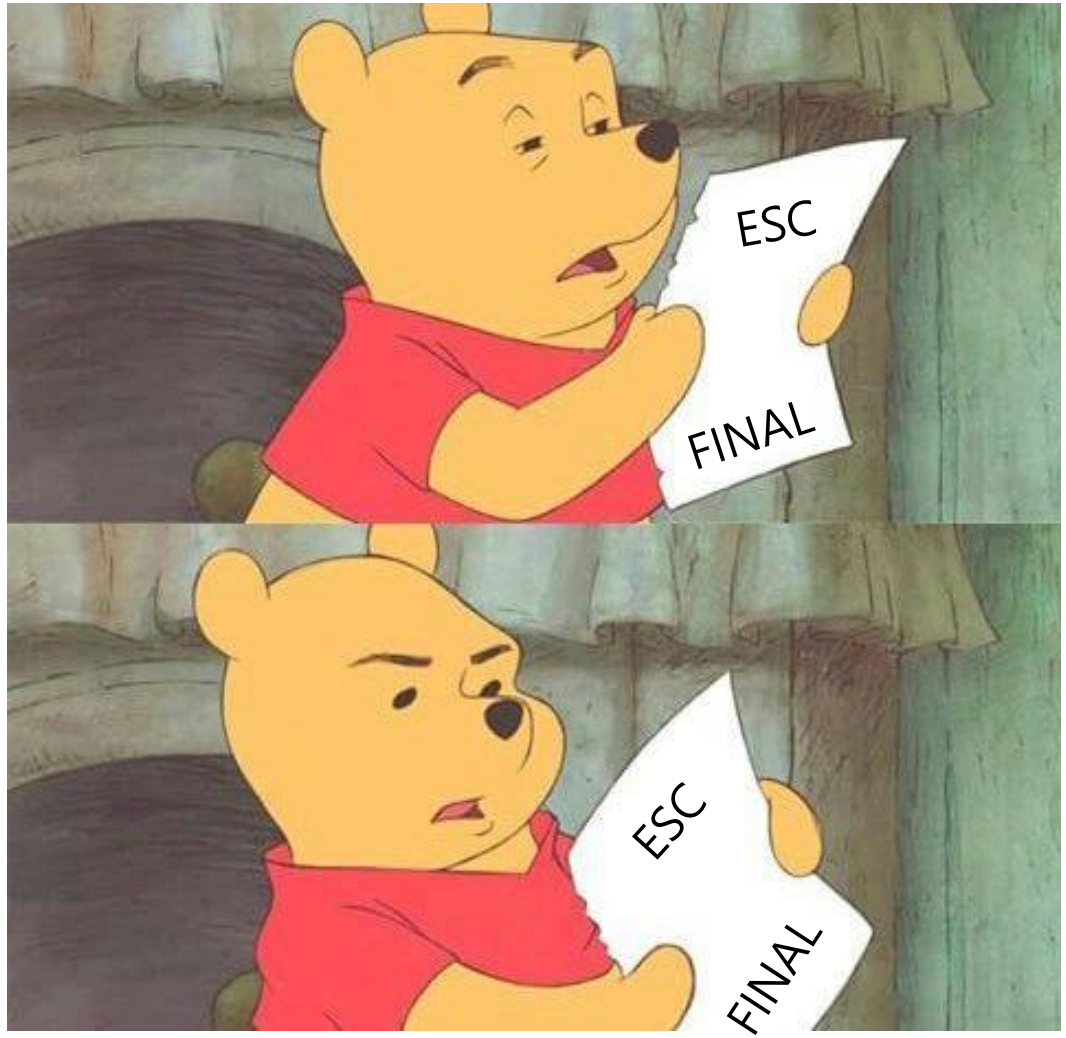


```
print(f"Shape: {df.shape}")
print(df.isnull().sum())
```

Shape: (6855, 65)

Attr1	0	Attr25	0	Attr50	15
Attr2	0	Attr26	15	Attr51	0
Attr3	0	Attr27	462	Attr52	60
Attr4	28	Attr28	162	Attr53	162
Attr5	15	Attr29	0	Attr54	162
Attr6	0	Attr30	14	Attr55	0
Attr7	0	Attr31	14	Attr56	14
Attr8	15	Attr32	72	Attr57	1
Attr9	0	Attr33	28	Attr58	10
Attr10	0	Attr34	15	Attr59	1
Attr11	0	Attr35	0	Attr60	420
Attr12	28	Attr36	0	Attr61	20
Attr13	14	Attr37	3100	Attr62	14
Attr14	0	Attr38	0	Attr63	28
Attr15	5	Attr39	14	Attr64	162
Attr16	15	Attr40	28	class	0
Attr17	15	Attr41	142	dtype: int64	
Attr18	0	Attr42	14		
Attr19	14	Attr43	14		
Attr20	14	Attr44	14		
Attr21	112	Attr45	418		
Attr22	0	Attr46	28		
Attr23	14	Attr47	57		
Attr24	149	Attr48	0		
		Attr49	14		

03

EDA

NA Imputation

1 Recovering Some Variables

- 대부분의 column에서 결측치가 발견되었다
- NA imputation 을 위해, 최대한 구할 수 있는 변수 값들은 구해보자. (NA 갯수가 0인 Attr 들을 이용)

EX)

```
total_assets = pd.Series(np.exp(df['Attr29']), index=df['Attr29'].index)
assert not bool(total_assets.isnull().sum())

total_equity = df['Attr10']* total_assets
assert not bool(total_equity.isnull().sum())

total_liabilities = total_assets - total_equity
assert not bool(total_liabilities.isnull().sum())

short_term_liabilities =  df['Attr51']  * total_assets
assert not bool(short_term_liabilities.isnull().sum())

long_term_liabilities = total_liabilities - short_term_liabilities
assert not bool(long_term_liabilities.isnull().sum())

total_sales = pd.Series(np.array(short_term_liabilities) * np.array(df['Attr36']))
assert not bool(total_sales.isnull().sum())
```

→

구할 수 있었던 정보들

total_assets
total_equity
total_liabilities
short_term_liabilities
long_term_liabilities
total_sales
Sales
gross_propit
retained_earnings
EBIT
EBITDA
net_profit
working_capital
profit_on_sales

무려 14개!

2 Delete Some Outliers

- 더 좋은 Imputation을 위해 Outlier도 제거해주자.

Attr11을 Log 변환

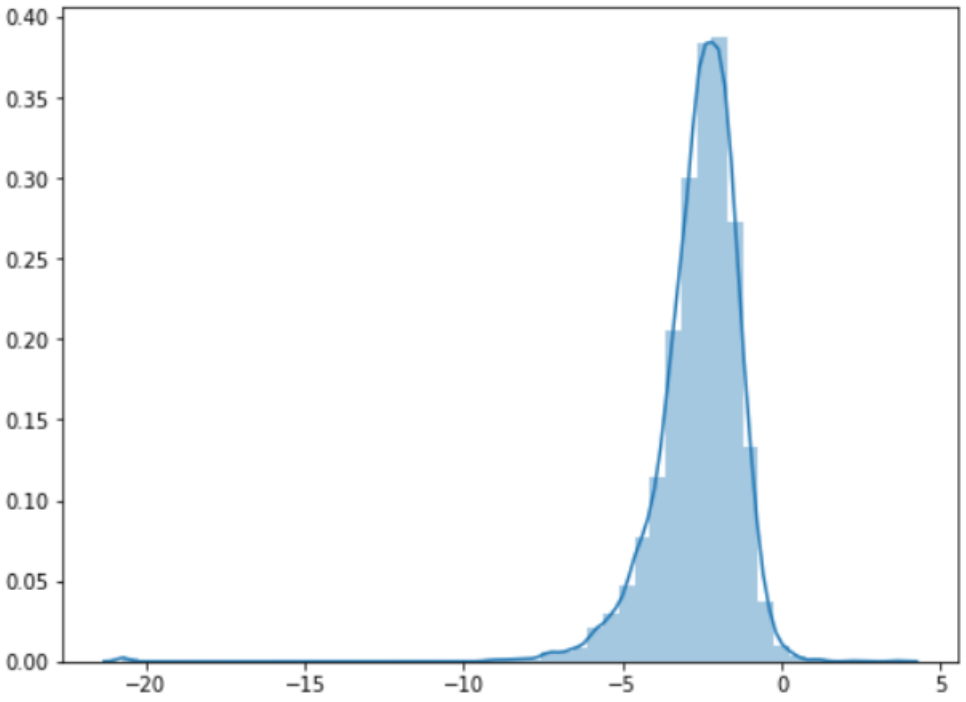


```
df['Attr11'].sort_values(ascending=True).index[0]
```

423 423 번째 데이터가 문제군! → 빼자

- 이런 식으로 density plot을 본 이후 수작업으로 아웃라이어들이 포함된 관측치를 삭제해준다.
- 하지만 class 1에 해당하는 관측치가 매우 적으니 아웃라이어여도 class 1,
  즉 부도난 회사의 데이터면 삭제하지 않는다.

3 Drop Useless Columns

- 변수가 가지고 있는 정보가 겹치거나, 눈으로 보았을 때 명확한 선형관계가 존재하면 제거해준다.

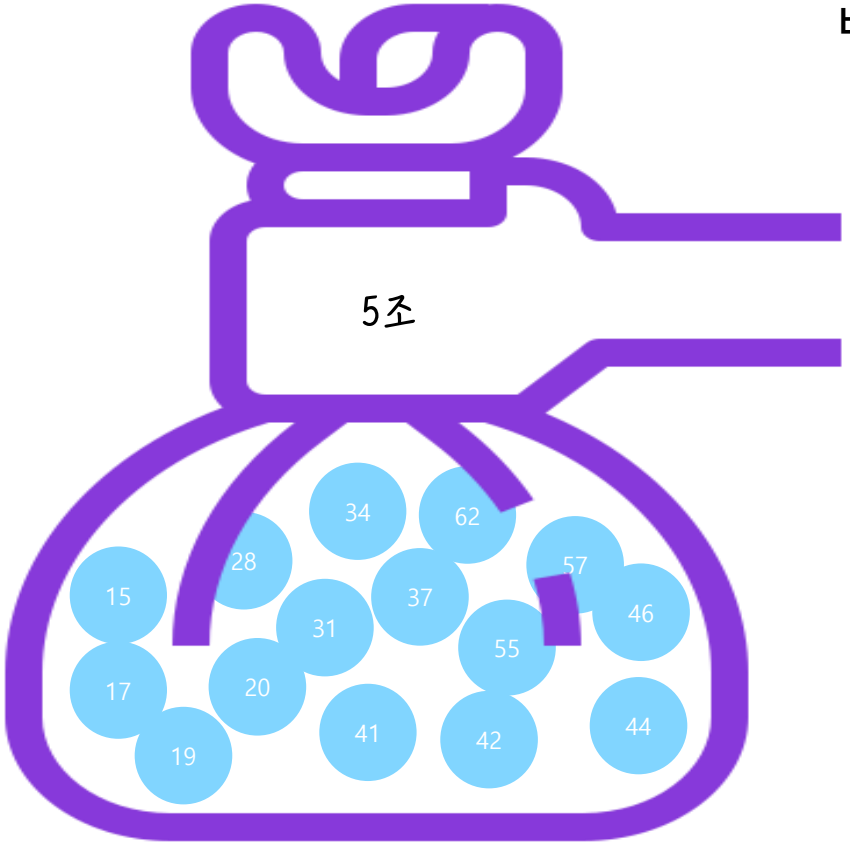

버린 변수들

X15 (total liabilities * 365) / (gross profit + depreciation)
X17 total assets / total liabilities
X19 gross profit / sales
X20 (inventory * 365) / sales
X28 working capital / fixed assets
X31 (gross profit + interest) / sales
X34 operating expenses / total liabilities
X37 (current assets - inventories) / long-term liabilities
X41 total liabilities / ((profit on operating activities + depreciation) * (12/365))
X42 profit on operating activities / sales
X44 (receivables * 365) / sales
X46 (current assets - inventory) / short-term liabilities
X55 working capital
X57 (current assets - inventory - short-term liabilities) / (sales - gross profit - depreciation)
X62 (short-term liabilities *365) / sales

4 Direct NA Imputation using recovered information

- 분모가 0이라서 NA값으로 뜨는 값들이 있었다.
- 이런 애들 중 아까 직접 구했던 정보들로 채울 수 있는 애들은 채워주자.

● 분모가 0이 되지 않기 위해 0 대신 최솟값 대입

```
min_short_term_liabilities = [x for x in np.sort(short_term_liabilities) if x][0]
short_term_liabilities.replace(0, min_short_term_liabilities, inplace=True)

min_sales = [x for x in np.sort(sales) if x][0]
sales.replace(0, min_sales, inplace=True)

min_total_liabilities = [x for x in np.sort(total_liabilities) if x][0]
total_liabilities.replace(0, min_total_liabilities, inplace=True)

min_total_equity = [x for x in np.sort(total_equity) if x][0]
total_equity.replace(0, min_total_equity, inplace=True)
```

● 최솟값 대입 후 가진 정보들로 다시 계산

```
df['Attr12'] = gross_profit / short_term_liabilities
df['Attr23'] = net_profit / sales
df['Attr39'] = profit_on_sales / sales
df['Attr49'] = EBITDA / sales
df['Attr50'] = current_assets / total_liabilities
df['Attr59'] = long_term_liabilities / total_equity
df['Attr63'] = sales / short_term_liabilities
```

→

● NA값 확인 → 없다!


```
df.loc[:, ['Attr12','Attr23','Attr39',
           'Attr49','Attr50','Attr59',
           'Attr63']].isnull().sum()
```

```
Attr12    0
Attr23    0
Attr39    0
Attr49    0
Attr50    0
Attr59    0
Attr63    0
dtype: int64
```

5 Using packages specialized in NA Imputation

그냥 NA 있는 Data들을 다 빼고 하면 되지 않아요?

- Measuring performance of Logistic Regression with na removed data

```
na_dropped = df.dropna(axis = 0)
X, y = na_dropped.iloc[:, :-1], na_dropped.iloc[:, -1]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, stratify = y, random_state=5)

lr = LogisticRegression(class_weight='balanced')
lr.fit(X_train, y_train)

y_pred = lr.predict(X_test)
print(f1_score(y_test, y_pred))
```

```
0.08823529411764706
```

매우 낮다.

우주야 파이널이 생각보다 녹록지 않다..

03

EDA

NA Imputation

5 Using packages specialized in NA Imputation

Simple Imputation

(Mean보단 Median의 성능이 더 좋았다)

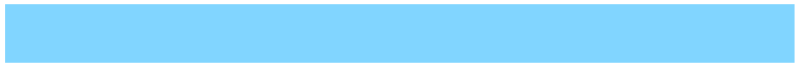

0.1769

얘로 하자

1

2

KNN Imputation

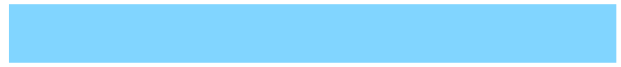

0.1567

CV
F1 score

Bayesian Ridge Imputation

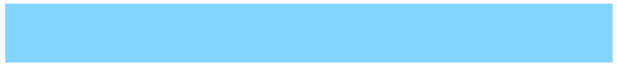

0.1567

3

4

Decision Tree Imputation

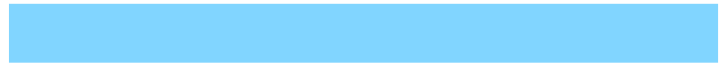

0.1577

5 Using packages specialized in NA Imputation

깔끔.

Median Imputer → NA 확인

Attr1	0	Attr33	0
Attr2	0	Attr35	0
Attr3	0	Attr36	0
Attr4	0	Attr38	0
Attr5	0	Attr39	0
Attr6	0	Attr40	0
Attr7	0	Attr43	0
Attr8	0	Attr45	0
Attr9	0	Attr47	0
Attr10	0	Attr48	0
Attr11	0	Attr49	0
Attr12	0	Attr50	0
Attr13	0	Attr51	0
Attr14	0	Attr52	0
Attr16	0	Attr53	0
Attr18	0	Attr54	0
Attr21	0	Attr56	0
Attr22	0	Attr58	0
Attr23	0	Attr59	0
Attr24	0	Attr60	0
Attr25	0	Attr61	0
Attr26	0	Attr63	0
Attr27	0	Attr64	0
Attr29	0	class	0
Attr30	0	dtype: int64	
Attr32	0		

EDA

Factor Analysis

그래도 여전히 변수가 너무 많다.(49개)
그런데 변수 꼴을 보아하니 변수들끼리 상관
관계가 있을 것 같다..

Factor Analysis

03

EDA

Factor Analysis

1 Scaling for Factor Analysis

- Factor Analysis를 하기 위해서는 Scaling이 우선.

- Scikitlearn에서 StandardScaler 사용

2 Draw Scree Plot using PCA

- FA에서 n_factor를 위해 우선 PCA Scree Plot을 그려보자

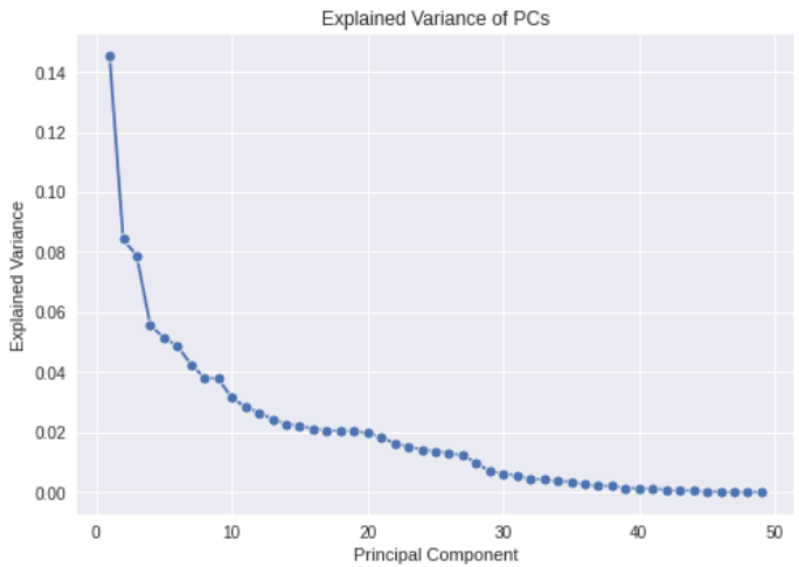

Explained Variance of PCs

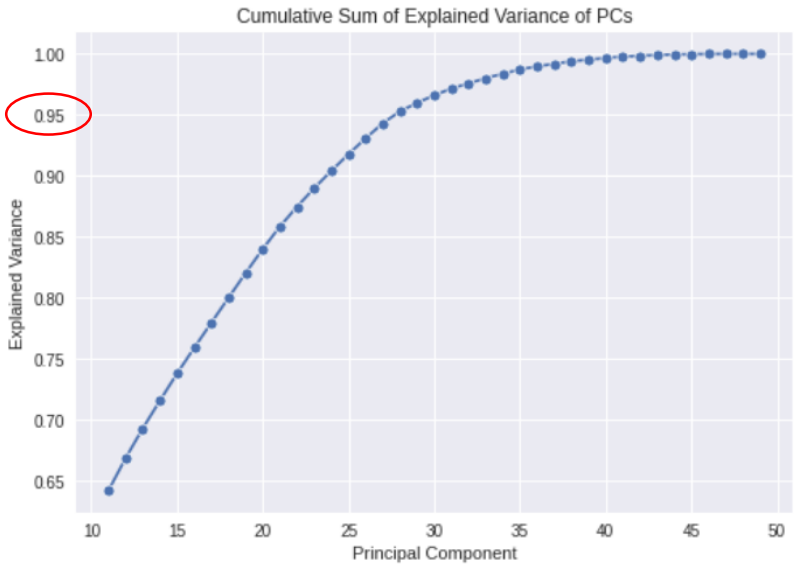

Cumulative Sum of
Explained Variance of PCs

한.. 30개 정도면 충분할 것 같다.

3 Draw Scree Plot using FA

- 이번에는 FactorAnalyzer를 이용해서 Scree plot을 그리자.

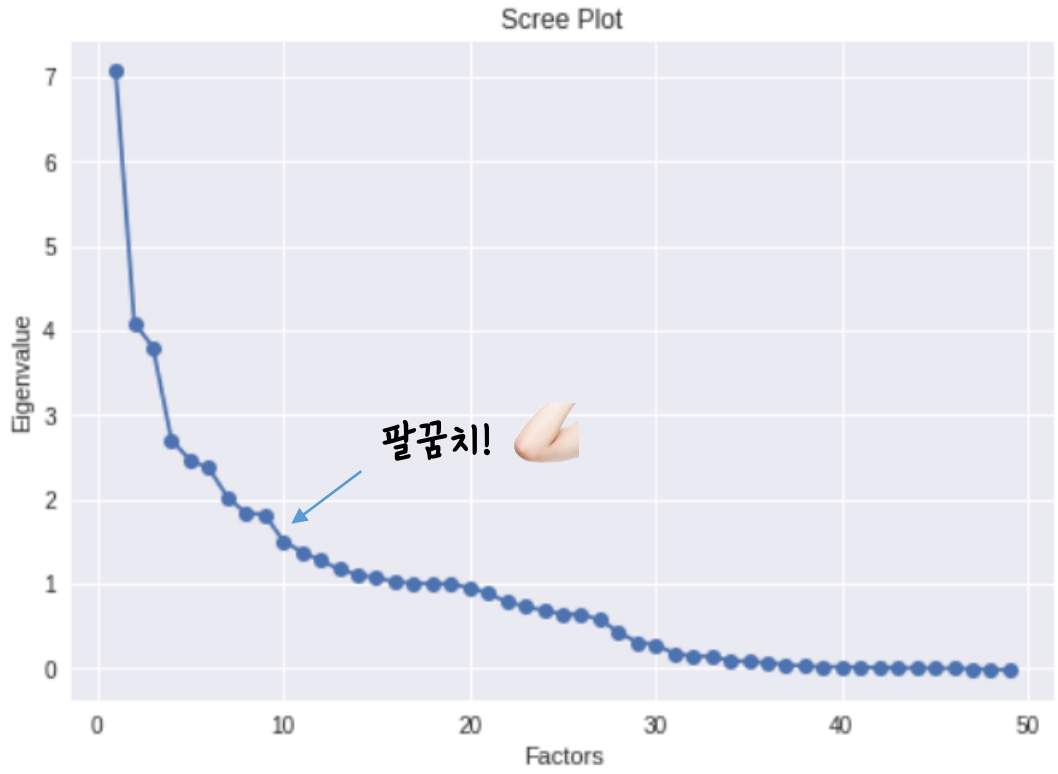

10개 정도의 Factor로 데이터를 설명할 수 있을 것 같다.

4 Factor Analysis

- Factor Analysis 를 통해 Factor에 어떤 변수들이 묶였는지 확인해보자.

● 우선 용이한 시각화를 위해 Factor 두 개만 살펴보자.

```
for i in range(1, 3):
  tmp = fa_df.iloc[i, :]
  top3 = list(np.argsort(-tmp.values)[:3].reshape(3,))
  bottom3 = list(np.argsort(tmp.values)[:3].reshape(3))
  print("Factor"+str(i))
  print(f"Top3 is {real_columns[top3[0]]}, {real_columns[top3[1]]}, {real_columns[top3[2]]}")
  print(f"Bottom3 is {real_columns[bottom3[0]]}, {real_columns[bottom3[1]]}, {real_columns[bottom3[2]]}")
  if i == 1:
    print("=" * 50)
```

```
Factor1
Top3 is equity / total assets, (equity - share capital) / total assets, constant capital / total assets
Bottom3 is total liabilities / total assets, short-term liabilities / total assets, (total liabilities - cash) /
sales
==================================================
Factor2
Top3 is (gross profit + depreciation) / total liabilities, (net profit + depreciation) / total liabilities, oper
ating expenses / short-term liabilities
Bottom3 is logarithm of total assets, short-term liabilities / total assets, profit on sales / total assets
```

잘 모르겠지만..

Factor1, Factor2 모두

재정건전성과 관련이 있는 것 같다..

4 Factor Analysis

- Factor Analysis 를 통해 Factor에 어떤 변수들이 묶였는지 확인해보자.

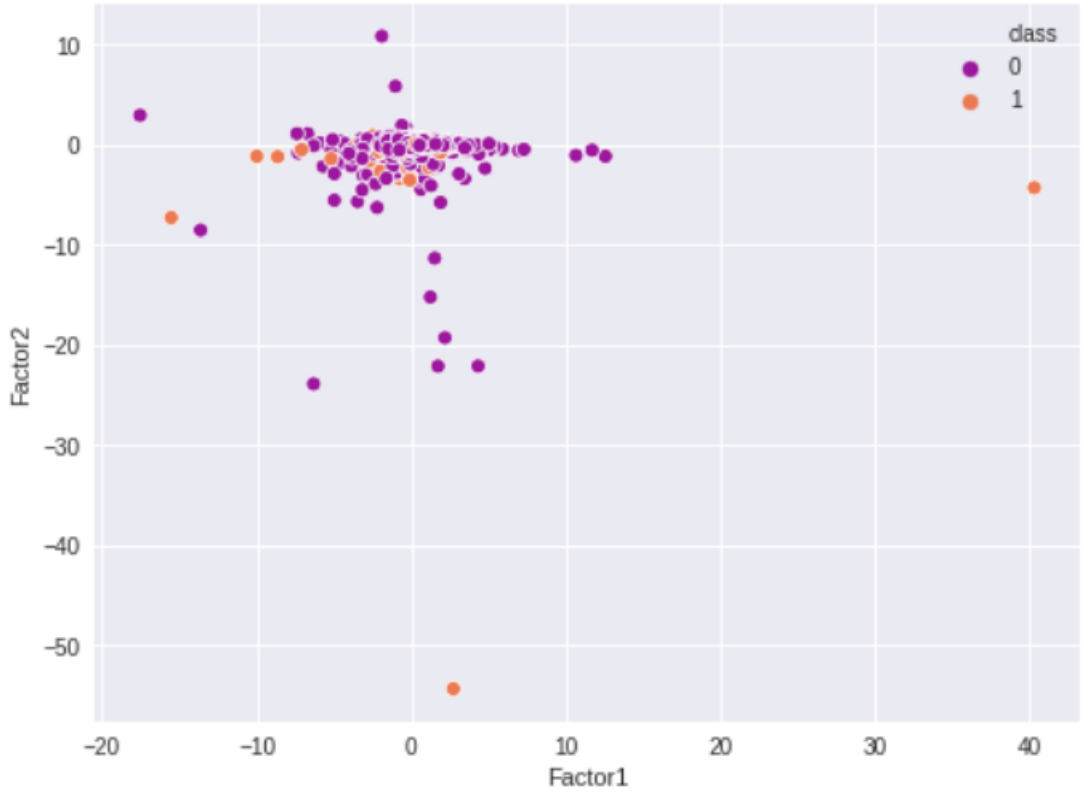

- 부도가 난 회사들은 대부분 Factor1의 - 부분과, Factor2의 0 부분에 위치하는 것으로 보아 재정건전성이 부족해 보인다
- 물론 Outlier도 존재.

4 Factor Analysis

- Factor Analysis 를 통해 Factor에 어떤 변수들이 묶였는지 확인해보자.

● 마지막으로 어떤 변수들의 정보량이 Factor에 많이 반영되었는지 알아보자.

```
top10 = np.argsort(-fa.get_communalities())[:10]

for t in top10:
  print(real_columns[t])
```

```
sales (n) / sales (n-1)
profit on operating activities / financial expenses
long-term liabilities / equity
[(cash + short-term securities + receivables - short-term liabilities) / (operating expenses - depreciation)] *
365
sales / receivables
net profit / sales
total costs /total sales
EBITDA (profit on operating activities - depreciation) / sales
(sales - cost of products sold) / sales
sales / total assets
```

→ Liablities, Profit, Sales 관련된 변수들이 많이 반영되었음을 알 수 있다.


추후 계획

04

추후 계획

Future Plan

Training

사용 가능한 모든 모델을 동원해서
모델을 학습

Selection

모델을 선택한다.

- 모델 자체의 선택
- 모델 내 변수 선택

Evaluation

모델의 예측성능 평가와
모델 해석

+ 종강총회


Thank You